

犀牛鸟开源 · 实战任务 2

AlgoTrace-Hy3

阶段 0：需求追踪与项目规划

项目负责人	郭昊杨 福州三中 信息学竞赛选手 NOIP 省一等奖
任务方向	可验证场景：过程评估与错误定位 > 算法竞赛
文档状态	阶段 0 基线 v1.0 2026 年 9 月 6 日
当前结论	方向成立；本地尚未初始化 Git；远程 GitHub 尚未创建或推送

身份声明：本项目及本文档是郭昊杨的个人/活动作品，非腾讯官方发布。任务书是约束来源；项目名、架构、题量、界面与指标细化是实施选择。

本轮仅完成本地需求追踪和规划；不创建远程仓库、不推送代码、不声称已完成 Hy3 实验或 demo。

1. 执行结论

一句话定位：AlgoTrace-Hy3 是一个基于 Hy3 的算法竞赛解题与过程审查工具，它把结构化解题说明、C++17 代码和独立测试结合起来，不只判断 AC/WA，还定位首个错误步骤、归类错误并给出可复核证据。

方向选择成立。洛谷适合检索候选题、参考难度和算法标签，但不能直接充当可复现评测集；最终题集必须具备可说明的来源、独立生成测试、参考解/检查器、过程标签和固定指标。

范围基线

范围	题量与轨迹	难度与覆盖	完成标准
MVP	8 题；每题至少 4 条轨迹，共不少于 32 条	A/B/C/D 各 2 题；覆盖基础实现、贪心/二分、DP/图论和数据结构	无密钥可用固定样例跑通「生成结构化解题—编译测试—过程评估—首错定位—结果导出」纵向切片
正式版	12 题；每题约 6 条轨迹，共约 72 条	A 基础 2、B 普及 3、C 普及+/提高- 4、D 提高 3；覆盖模拟/枚举、贪心、排序、二分、DP、图论、并查集和树状数组/线段树	真实 Hy3 实验、人工抽检、指标报告、2 分钟内 demo、公开 GitHub 并经干净克隆复现

阶段计数说明：总提示词列出“阶段 0—阶段 7”，按编号实际为 **8 个阶段**；其中阶段 0 是需求基线，阶段 1—7 是 7 个实施与交付阶段。本文按这一无歧义结构执行。

2. 官方硬要求 / 我的选择 / 实施建议

维度	官方硬要求（任务书）	我的选择（当前基线）	实施建议（可调整）
仓库与身份	自行创建公开仓库；无需向 Hy3 官方仓库提 PR；README 写项目介绍、运行方式、环境要求；项目名与 README 标明个人/活动作品	暂定项目名 AlgoTrace-Hy3 ；作者为郭昊杨、福州三中；非腾讯官方发布	本地内容完成、秘密扫描和干净复现后再公开；远程操作须先确认账号、仓库名、许可证与公开范围

维度	官方硬要求（任务书）	我的选择（当前基线）	实施建议（可调整）
模型与密钥	能力调用通过 Hy3；不需要训练或微调；API Key 不得硬编码或提交	OpenAI-compatible 适配层；配置名拟为 HY3_BASE_URL、HY3_API_KEY、HY3_MODEL、HY3_TIMEOUT	提供 .env.example，真实密钥只放本机环境变量/未跟踪 .env；无端点时使用固定 fixtures
应用输出	可运行；针对题目产出完整解答过程，不能只输出最终答案	使用公开、结构化的解题说明协议：题意、步骤、算法、正确性依据、复杂度、边界、代码	用 JSON Schema 约束字段和步骤依赖；不索取、不保存模型不可见的隐藏思维链
评测题集	每题有明确标准答案和自动校验；按难度分层；说明来源、构造、覆盖和分层依据	洛谷只用于检索、难度与标签参考；优先自编/重述规格、自己写参考解、生成器与测试	先 8 题后 12 题；固定随机种子；为每题维护 metadata.yaml、规格、参考解、生成器、检查器、rubric 和 tests
过程评估	判断过程正确性；定位错误开始步骤；建立错误分类；识别结果正确但过程不成立	E1—E8 分类；first_error_step 唯一；允许次级类型	采用确定性执行 + 规则 + Hy3 分步审查 + 冲突/低置信度复核；所有结论附证据与置信度
有效性验证	至少验证定位准确率和误报率；答案正确样本需人工抽检真实问题与误报比例	预先冻结 Exact/Relaxed Localization、Recall、FPR、Macro-F1 等定义	gold 标签必须独立于评估器预测；至少人工复核全部错误样本及“答案对/过程错”样本
结果分析	输出最终答案准确率、过程正确率、错误类型分布、难度分层结果；指出明显下降区间	按难度和算法类型分组，报告样本量；正式实验后再填数	小样本只写“观察到的下降”；使用预先声明的相邻层下降规则和 bootstrap 区间，禁止虚构结果
完整产出	源码、过程评估模块、题集、标准答案、脚本、完整结果、验证数据、抽检记录、分析报告、2 分钟内视频/GIF	仓库结构按 src/、benchmarks/、annotations/、experiments/、results/、reports/、demo/、tests/、.github/ 组织	建立需求 ID 到文件、命令和证据的追踪；CI 仅运行无密钥检查与固定样例

3. 需求追踪矩阵

状态含义：**已核对** 表示需求已从任务书确认并完成追踪设计；**待实现** 表示尚无对应工程产物；**待外部确认** 表示执行会产生远程公开写入或依赖用户专有配置。

ID	来源	可验收要求	计划落点	验收命令/证据	当前状态
SUB-01	PDF p1	创建并维护公开仓库，完成后提交仓库链接；不向 Hy3 官方仓库提 PR	README.md、远程 GitHub	<code>git remote -v</code> ；公开仓库 URL；干净克隆日志	待外部确认
SUB-02	PDF p1	README 含项目介绍、运行方式、环境要求	README.md	<code>python scripts/check_readme.py</code>	待实现
SUB-03	PDF p1	不提交 API Key；密钥经环境变量或配置传入	<code>.env.example</code> 、 <code>.gitignore</code> 、 <code>src/.../hy3_client.py</code>	<code>python scripts/scan_secrets.py</code> ；CI secret scan	待实现
SUB-04	PDF p1	项目名与 README 标明个人/活动作品，避免误认为腾讯官方	README.md、报告首页	README 首屏声明；人工检查	待实现
SUB-05	PDF p1	模型能力调用通过 Hy3，不训练/微调	<code>hy3_client.py</code> 、实验配置	配置快照、请求日志（脱敏）、模型名	待实现
APP-01	PDF p3	构建可运行应用，输出完整解答过程而非仅最终答案	CLI/可选 Web UI、Schema	<code>python -m algotrace_hy3 solve --fixture ...</code>	待实现
SET-01	PDF p3	每题有明确标准答案和自动判定	<code>benchmarks/problems/<id>/</code>	<code>python scripts/validate_benchmark.py --all</code>	待实现
SET-02	PDF p3	题目按难度分层并覆盖基础到高难；说明来源、构造、覆盖、依据	<code>problem_catalog.yaml</code> 、题目 metadata、选题报告	catalog schema 校验；人工来源复核	待实现
EVAL-01	PDF p3	判断推理链是否成立及跳步、误用、遗漏、幻觉等问题	<code>evaluator/rules.py</code> 、 <code>llm_judge.py</code> 、rubric	evaluator golden tests	待实现
EVAL-02	PDF p3	定位错误开始出现的步骤	<code>aggregate.py</code> 、结构化预测 Schema	<code>pytest tests/evaluator/test_localization.py -q</code>	待实现

ID	来源	可验收要求	计划落点	验收命令/证据	当前状态
EVA L-03	PDF p3	建立并输出错误类型	annotations/ guideline.md、E1—E8 枚举	taxonomy schema + 标注抽检	待实现
EVA L-04	PDF p3	识别结果正确但过程不成立	四象限样本、golden cases	pytest -k correct_answer_wrong_proc ess -q	待实现
EVA L-05	PDF p3	可采用规则、分步 LLM、沙盒、多 Agent 等实现	混合评估器	组件消融和冲突日志	实施选择
VAL-01	PDF p3-p4	在答案错误样本上 验证检测与首错定 位准确率	annotations/ gold.jsonl、 results/ metrics.json	python scripts/compute_metrics.p y	待实现
VAL-02	PDF p4	对答案正确但被判 过程有问题的样本 人工抽检，区分真 实问题和误报	annotations/ manual_audit.csv	审计记录完整性校验	待实现
RES-01	PDF p4	输出最终答案准确 率、过程正确率、 错误类型分布	results/ summary.csv、图表	python scripts/validate_results. py	待实现
RES-02	PDF p4	按难度分析并指出 表现明显下降区间	reports/analysis.md	分层表、样本量、预声明规则和区间	待实现
OUT-01	PDF p4	开源项目仓库含应 用源码、过程评估 模块、 README、环境 样例、运行说明	仓库根目录、src/	CI；干净克隆复现	待实现
OUT-02	PDF p4	分层题集、标准答 案、答案校验和过 程评估脚本	benchmarks/、 scripts/	python scripts/reproduce_all.py --offline	待实现
OUT-03	PDF p4	完整结果与有效性 验证数据、人工抽 检记录	results/、 annotations/	文件清单与哈希清单	待实现
OUT-04	PDF p4	分析报告含方法依 据、分类、案例、 能力边界与临界点	reports/ final_report.*	报告构建与数据引用检查	待实现

ID	来源	可验收要求	计划落点	验收命令/证据	当前状态
OUT-05	PDF p4	2 分钟以内 demo 视频或 GIF，展示完整流程	demo/	媒体时长检查；演示清单	待实现

4. 阶段 0 本地只读检查结果

已确认事实

1. 原始任务书可读取，共 4 页；通用提交要求位于第 1 页，任务 2 的应用、题集、评估、验证、结果和产出要求位于第 3—4 页。
2. 当前工作目录为 `/Users/vivi2026/Desktop/codex-work/2026-09-06/noip-2-github`。
3. 当前目录**不是 Git 工作树**，没有 `.git`，因此也不存在已配置远程仓库或待推送提交。
4. 当前只有 `outputs/` 中的项目总提示词 Word/PDF，以及 `work/` 中的排版脚本和渲染中间文件；尚无应用源码、题集、测试、CI 或实验结果。
5. 截图中郭昊杨对应行未见 GitHub 链接，可作为“当前未提交链接”的辅助进度信息，但不是技术验收证据。
6. Hy3 官方仓库当前 README 提供 vLLM/SGLang 部署方案和 OpenAI-compatible API 示例；具体端点和模型配置仍应由环境变量提供，不能写死。
7. 洛谷官方当前将题目难度分为八档，并明确说明难度评定具有主观性、仅供训练参考；洛谷官方也限制测试数据下载，部分题目因版权不提供数据。

已知假设

- 默认开发环境为 macOS，本地编排使用 Python，候选程序使用 C++17。
- 先建设离线可复现路径；有 Hy3 端点后再运行真实模型实验。
- MVP 使用 8 道题和不少于 32 条轨迹；正式目标 12 道题和约 72 条轨迹。这是工程范围，不是任务书规定的最低题数。
- 单题题面是否能完整收入仓库要逐题审查；未确认许可时仅保存题号、链接、自己的摘要/形式化规格与独立生成数据。

5. 八阶段路线图（阶段 0—7）

阶段	主要交付物	验收命令（目标形态）	主要风险与控制
0 需求追踪	本文、边界矩阵、需求 ID、现状与风险基线	<code>test -f requirement_traceability.md</code> ; Word/PDF 渲染核验	误把实施建议当官方要求; 逐项标 PDF 页码并分栏
1 选题与方案	候选题矩阵、许可/引用检查、分层规则、8 题 MVP、错误分类与标注规范	<code>python scripts/validate_problem_catalog.py</code>	版权、题型失衡、难度漂移; 优先自编规格和独立测试, 保留来源/访问日期
2 工程骨架	本地 Git、Python 包、CLI、Schema、Hy3 适配器、 <code>.env.example</code> 、测试和无密钥 CI	<code>python -m pytest -q</code> ; <code>python -m algotrace_hy3 --help</code>	过早做大界面; 先做一题纵向切片与离线 fixture
3 题集与安全执行	参考解、固定种子生成器、检查器、边界测试、性质测试、受限执行器	<code>python scripts/reproduce_problem.py --all --seed 20260906</code>	不可信代码逃逸、平台隔离差异; 禁网、限时限存限进程并醒目标风险
4 过程评估	规则层、Hy3 分步审查、聚合器、首错定位、E1—E8、证据与置信度	<code>pytest tests/evaluator -q</code> ; golden cases 全通过	LLM 结论不稳定或强行判定; 固定 rubric、低随机性、unknown、复核路径
5 实验验证	冻结数据/配置、真实与离线运行、原始 JSONL、gold、人工抽检、指标和失败日志	<code>python scripts/run_eval.py --config experiments/configs/main.yaml</code> ; <code>python scripts/compute_metrics.py</code>	无 Hy3 资源、标签泄漏、小样本; fixtures 先通链路, gold 独立维护, 真实结果标时间戳
6 报告与演示	结果表、难度曲线、错误分布、典型案例、最终报告、≤2 分钟 demo	<code>python scripts/build_report.py</code> ; 媒体时长 ≤120 秒; 数据引用检查	选择性报告或夸大临界点; 冻结题集后运行, 保留负面结果并报告样本量/区间
7 GitHub 交付	公开仓库、许可证、CI、秘密扫描、干净克隆复现、可提交链接	<code>git status --short</code> ; <code>secret scan</code> ; <code>gh repo view</code> ; 临时目录干净克隆复现	误公开密钥/个人信息、推送未完成内容; 执行前再次确认账号、名称、许可证和公开范围

6. 最多 5 个真实阻塞项

这些事项不会阻塞阶段 1—4 的本地开发，但会阻塞相应里程碑；当前无需立即回答。

8. **真实 Hy3 实验资源**：缺少可用端点、模型标识和本地环境变量时，只能完成离线 fixture，阶段 5 的真实模型结果不能宣称完成。
9. **GitHub 发布参数**：GitHub 用户名、最终仓库名、许可证、公开内容范围和是否立即推送未确认，阶段 7 不得执行远程创建/推送。
10. **最终题目许可与引用策略**：每个候选题能否完整收录、是否仅链接、哪些部分由自己重新形式化，必须在阶段 1 逐题完成证据检查后才能冻结题单。
11. **第二标注者可用性**：若无法邀请教练或另一名选手复核，仍可完成单人 gold，但一致率无法估计，必须在报告中作为局限披露。
12. **活动截止日期与最终提交入口**：原 4 页任务书未写明截止日期或表单规则；不影响本地实现，但会影响排期和最终提交动作，需要在官方活动通知中确认。

7. 风险登记

风险	概率/影响	触发信号	应对
评估器 把“解释简略”误判为“过程错误”	中/高	正确轨迹 FPR 偏高	rubric 区分“不充分”“错误”“unknown”；答案正确样本人工抽检
测试通过但 算法逻辑有缺陷	高/高	弱测下错误解 AC	生成器 + 性质测试 + 对抗样本 + 反例最小化；重点保留结果对/过程错样本
复杂度声明 与实现不一致	中/中	文本称 $O(n \log n)$ ，实现出现嵌套扫描	静态启发式只给风险提示，结合规模压测和 Hy3 复核，不做无证据断言
不可信代码 执行危害主机	中/高	候选代码访问网络/文件或 fork	Docker/受限子进程、禁网和资源上限；隔离不可用时默认不执行陌生代码并写明风险
题集规模挤 压标注质量	高/高	为赶 12 题跳过 gold 或测试	先冻结 8 题 MVP；每增加一题必须贡献新难度、算法或错误模式

风险	概率/影响	触发信号	应对
模型评审波动导致指标不可复现	中/高	同样本重复判断不一致	固定模型/参数/提示词/种子；保存脱敏原始响应；报告重复试验波动
公开仓库泄露密钥或个人信息	低/极高	.env、日志、绝对路径进入暂存区	.gitignore、pre-commit/CI secret scan、人工清单、干净克隆检查

8. 阶段 0 验收清单

- ☒ 逐页读取原始 4 页任务书并区分文档要求与实施选择。
- ☒ 核查当前工作区、文件清单和 Git 状态。
- ☒ 核验 Hy3 官方仓库及洛谷官方难度/题目说明（访问日期：2026-09-06）。
- ☒ 建立官方硬要求 / 我的选择 / 实施建议三栏边界。
- ☒ 建立带来源页码、交付物、验收证据与状态的需求追踪矩阵。
- ☒ 固化 MVP、正式版范围、阶段 0—7 路线图、风险和最多 5 个阻塞项。
- ☐ 初始化本地 Git 和工程骨架——属于阶段 2，不在本轮只读核查边界内。
- ☐ 创建/推送 GitHub——属于阶段 7，必须取得发布参数和明确授权。

9. 下一步执行建议

直接进入**阶段 1：选题与方案**。先建立 16—20 道候选题矩阵，再按“来源/许可可说明、离线可复现、可独立生成测试、错误模式有价值、算法覆盖互补”筛成 8 题 MVP。不要先把洛谷题面或测试数据复制进仓库，也不要先做 UI。

阶段 1 完成后进入阶段 2：初始化本地 Git 和 Python 工程，以 1 道基础题跑通第一个纵向切片。远程 GitHub 仍保持未创建状态，直到阶段 7 前得到确认。

10. 依据与访问记录

- 本地任务书：《犀牛鸟开源·实战任务·混元大语言模型项目》，4 页；任务 2 见第 3—4 页，通用提交要求见第 1 页；核对日期 2026-09-06。
- Hy3 官方仓库：<https://github.com/Tencent-Hunyuan/Hy3>（访问日期 2026-09-06）。
- 洛谷帮助中心·题目难度体系：<https://help.luogu.com.cn/manual/luogu/problem/difficulty>（访问日期 2026-09-06）。
- 洛谷帮助中心·题目：<https://help.luogu.com.cn/manual/luogu/problem/>（访问日期 2026-09-06）。
- 洛谷帮助中心·查找题目：<https://help.luogu.com.cn/manual/luogu/problem/search>（访问日期 2026-09-06）。