

犀牛鸟开源 · 实战任务 2

AlgoTrace-Hy3

阶段一选题与评测集设计

郭昊杨 福州三中 信息学竞赛选手 NOIP 省一等奖
可验证场景：算法竞赛解法的过程评估与错误定位
github.com/EvanGuo202608/hy3-algo-process-eval
v1.0 2026 年 9 月 7 日
20 题候选矩阵、8 题 MVP、12 题扩展方案、标注与测试设计

身份声明：本项目及本文档是郭昊杨的个人/活动作品，非腾讯官方发布。任务书是约束来源；题量、分层和工程方案属于个人实施设计。

真实性声明：本阶段只完成选题和评测集设计。代码、测试、Hy3 调用、实验指标、人工复核和 demo 仍需在后续阶段真实完成。

1 阶段结论

阶段一采用“洛谷检索与难度参考 + 独立形式化规格 + 自编生成器和测试 + 自写参考解”的题集路线。洛谷题目用于确定算法类型、难度和公开来源，不下载、不提交其私有测试数据，也不复制第三方题解。

首批 8 题 MVP 已确定：P1909、P1047、P1094、P1873、P8816、P3366、P3373、P2680。它们覆盖模拟与枚举、区间处理、排序与贪心、二分答案、动态规划、图论与并查集、线段树、树上综合算法。正式版增加 P1090、P7074、P5658、P5022，形成 12 题分层题集。

项目评估的对象是公开、结构化、可核验的解题说明和 C++17 代码，不索取或保存模型的隐藏思维链。每题先建立参考解、生成器、检查器和 rubric，再制作四象限轨迹。任何未运行的实验结果都保持为 pending。

2 仓库检查结果

2026-09-07 对公开仓库链接进行了只读检查。

检查项	结果	处理
仓库主页	可公开访问	通过
PROJECT_PLAN.md	可访问	通过
docs/planning/requirement_traceability.md	可访问	通过
阶段 0 PDF	可访问	通过
阶段 0 DOCX	返回 404	后续补传，不阻塞阶段一

建议在完成本阶段上传后，再检查 README 中所有相对链接。仓库当前的核心规划链路已经成立。

3 资料依据与使用边界

3.1 官方资料

本阶段只将官方页面作为事实依据，算法判断和内部难度属于本项目的技术分析。

1. 洛谷题目难度：洛谷把难度划分为八档，同时说明难度带有主观性，仅供训练参考。
2. 洛谷题目搜索：题目可按难度、来源和算法等条件筛选。

3. 洛谷题目与评测说明：部分测试数据会因版权原因不可下载，错误数据下载也受限制。
4. 各候选题的洛谷官方题目页，链接见候选矩阵与 MVP 表。

3.2 仓库内容边界

仓库可以保存：题号、标题、官方链接、来源赛事、自己撰写的约束摘要、自编的等价形式化规格、参考解、生成器、检查器、测试元数据和标注。

仓库不保存：洛谷私有测试、批量抓取的数据、他人题解全文、未经许可的完整题面或图片、模型或选手不可见的内部思维链。

如需完全离线复现，优先采用自编等价规格。等价规格必须改写叙事和文字，只保留可公开引用的算法结构，并记录原始灵感链接、改写范围和测试构造方法。

4 项目内部难度规则

洛谷颜色只作为外部参考。项目使用四层内部难度，以便解释过程评估为什么会变难。

层级	判断规则	主要评估重点
A 基础	单一算法核心；实现通常不超过约 60 行；主要风险来自题意、下标和边界	E1、E5、E8
B 普及	需要一种标准算法与清楚的不变量或单调性；错误常能被小反例触发	E2、E3、E4、E5
C 普及+/提高-	需要状态设计、图模型或数据结构；正确性依赖多个步骤	E2、E3、E4、E6
D 提高	算法模块组合、实现细节多、弱测试容易漏错；首错定位存在跨步骤依赖	E2、E3、E4、E5、E6、E7、E8

分层时同时记录算法知识点、预期代码长度、参考复杂度、错误模式和测试构造成本。内部层级可以与洛谷颜色不同，但必须解释差异。

5 候选题评分方法

每题按五项评分，总分 10 分：算法覆盖 0–2，错误定位价值 0–3，独立测试可构造性 0–2，MVP 实施成本 0–2，引用边界清晰度 0–1。分数用于选题，不代表官方难度或题目质量。

入选还必须满足四项门槛：官方链接可核验、能独立构造测试、能写出无争议参考解、能设计有价值的首错样本。

P14080《最小生成树》没有进入候选矩阵。该题要求评估删去每条边后的最小生成树，工程成本明显高于普通最小生成树，会放大首版题集开发风险。P3366 更适合验证图论、贪心证明与并查集实现。

6 二十题候选矩阵

编号	洛谷题目	外部难度参考	主要算法	内部层级	重点错误	分数	决定
C01	P1909 买铅笔	入门	枚举、向上取整	A	E1、E5、E8	10	MVP
C02	P1047 校门外的树	入门	标记或差分	A	E1、E5、E6	10	MVP
C03	P1980 计数问题	入门	数位枚举	A	E1、E5	7	备选
C04	P5015 标题统计	入门	字符串扫描	A	E1、E5	6	备选
C05	P1094 纪念品分组	普及-	排序、双指针贪心	B	E3、E4、E5	10	MVP
C06	P1873 砍树	普及-	二分答案	B	E3、E4、E5	10	MVP
C07	P1540 机器翻译	普及-	队列、集合	B	E1、E5、E6	8	备选
C08	P1030 求先序排列	普及-	递归、二叉树遍历	B	E2、E5、E6	8	备选
C09	P1090 合并果子	普及	优先队列、贪心	B	E3、E4、E5	9	正式版
C10	P2678 跳石头	普及	二分答案、贪心检查	B	E3、E5	8	备选
C11	P1083 借教室	普及	二分、差分	C	E3、E4、E5	8	备选
C12	P2058 海港	普及	滑动窗口、计数	C	E1、E5、E6	8	备选
C13	P8816 上升点列	普及	排序、动态规划	C	E2、E3、E5	10	MVP
C14	P3366 最小生成树	模板题；颜色单独记录	Kruskal、并查集	C	E2、E3、E5、E6	10	MVP
C15	P3373 线段树 2	普及+/提高-	线段树、复合懒标记	D	E4、E5、E6	10	MVP
C16	P5658 括号树	普及+/提高-	树形 DP、栈、回溯	C	E2、E3、E6	9	正式版
C17	P7074 方格取数	普及+/提高-	双向扫描 DP	C	E2、E3、E5	9	正式版
C18	P4170 涂色	提高	区间 DP	D	E2、E3、E5	8	备选
C19	P2680 运输计划	提高	LCA、树上差分、二分	D	E2、E3、E4、E6	10	MVP
C20	P5022 旅行	提高	图搜索、基环树讨论	D	E2、E3、E6、E7	9	正式版

7 八题 MVP 冻结清单

内部 ID	来源	内部层级	参考算法	参考复杂度	主要诊断价值
A01-pack-cost	P1909	A	枚举三种包装并做整数向上取整	$O(1)$	题意重述、整除边界、整数公式
A02-interval-removal	P1047	A	布尔标记或差分	$O(L+M)$ 或 $O(L+M \log M)$	闭区间端点、重叠区间、0 号位置
B01-pairing	P1094	B	排序后双指针贪心	$O(n \log n)$	贪心交换论证、指针停止条件
B02-cut-height	P1873	B	单调判定与二分答案	$O(n \log H)$	单调方向、最大可行值、64 位累加
C01-rising-points	P8816	C	按坐标排序的动态规划	$O(n^2)$	状态含义、可添加点预算、转移条件
C02-minimum-network	P3366	C	Kruskal 与并查集	$O(m \log m)$	割性质、连通性、并查集实现
D01-range-affine-sum	P3373	D	维护乘法和加法标记的线段树	$O((n+q) \log n)$	标记复合顺序、模运算、区间长度
D02-route-upgrade	P2680	D	LCA、路径统计、二分答案	$O((n+m) \log n \log W)$ 级别	多模块依赖、可行性证明、树上差分

7.1 A01 pack cost

- 最小测试：需求量 1；包装数量大于需求；价格差异极大。
- 关键测试：需求量恰好整除；差 1 才能整除；单位价格低但总价并非最优。
- 预设错误：浮点 `ceil` 转换问题；写成整除下取整；比较单位价格而非总价格。
- 结果对过程错样本：代码枚举总价正确，但说明声称“单位价格最低一定最优”。

7.2 A02 interval removal

- 最小测试： $L=0$ ；单个区间 $[0,0]$ ；删除整段 $[0,L]$ 。
- 关键测试：区间相交、包含、相邻、重复；端点 0 和 L 。
- 预设错误：把 $[l,r]$ 当成半开区间；初始树数写成 L 而非 $L+1$ ；重复删除重复扣减。
- 结果对过程错样本：差分代码正确，解释却遗漏闭区间右端点。

7.3 B01 pairing

- 最小测试：一个物品；两个物品恰好能配对；所有物品只能单独放。
- 关键测试：大量重复重量；轻重恰好等于上限；最轻与最重不能配时的推进。
- 预设错误：让两个最轻先配；两端指针同时移动；遗漏奇数个物品。

- 结果对过程错样本：双指针代码正确，但证明只凭直觉，没有说明与最重物品配对的交换性质。

7.4 B02 cut height

- 最小测试：一棵树；所需木材恰好为某个切割高度产生的值。
- 关键测试：全部等高；高度差悬殊；答案 0；总和超过 32 位整数。
- 预设错误：单调方向反转；找最小可行值；左右边界更新造成死循环；使用 int 累加。
- 结果对过程错样本：代码返回最大可行高度，说明却把判定函数描述为随高度单调不减。

7.5 C01 rising points

- 最小测试：单点且 $k=0$ ；两点可直接连接；两点需要恰好 k 个补点。
- 关键测试：相同 x 或相同 y ；不可比较点；坐标到 10^9 ；剩余补点应加入链尾。
- 预设错误：曼哈顿距离少减 1；状态不包含或错误消耗补点；忘记排序；答案忘加剩余 k 。
- 结果对过程错样本：代码采用正确 DP，文字把欧几里得距离条件直接等同为任意两点的曼哈顿距离。

7.6 C02 minimum network

- 最小测试：单点、单边、两条等权边。
- 关键测试：重边、零权、负权等自编扩展；图不连通；多个 MST；长链并查集。
- 预设错误：未按边权排序；已连通边仍加入；并查集方向或初始化错误；不检查选中 $n-1$ 条边。
- 结果对过程错样本：代码为正确 Kruskal，证明声称“每次选全图最小边必然安全”，却没有排除成环边。

7.7 D01 range affine sum

- 最小测试： $n=1$ ；整段与单点更新；模数为 1。
- 关键测试：先乘后加与先加后乘；多层懒标记；乘 0；大数取模；左右边界相同。
- 预设错误：加法标记未随乘法缩放；乘法标记初值为 0；区间和增加时遗漏区间长度；下传顺序错误。
- 结果对过程错样本：代码正确维护仿射变换，说明却宣称加法与乘法标记可交换。

7.8 D02 route upgrade

- 最小测试：两个节点和一条计划；所有边权为 0；所有计划相同。
- 关键测试：链、星形、随机树；最长路径不唯一；候选边只覆盖部分超限计划； n 、 m 大规模。
- 预设错误：二分判定只检查最长一条路径；树上差分符号或 LCA 扣减错误；升级边不在所有超限路径交集；复杂度退化。
- 结果对过程错样本：代码验证所有超限路径，说明却只用一条最长路径推导候选边。

8 正式版十二题结构

层级	题目	数量	增量价值
A	P1909、P1047	2	题意、端点、格式和基础数值错误
B	P1094、P1873、P1090	3	两类贪心证明与二分单调性
C	P8816、P3366、 P7074、P5658	4	线性/二维/树形 DP、图与回溯状态
D	P3373、P2680、P5022	3	数据结构标记复合、树上综合、图结构分类

扩题顺序为 P1090、P7074、P5658、P5022。每次只增加一道题，先完成参考解、生成器、检查器和四条带 gold 的轨迹，再进入下一题。

9 错误类型覆盖

错误类型	MVP 主要承载题	最低目标样本
E1 题意或约束误读	A01、A02、C01	3
E2 建模或算法错误	B01、C01、C02、D02	4
E3 正确性论证错误	B01、B02、C02、D02	4
E4 复杂度错误	B01、B02、D01、D02	4
E5 边界或数值错误	全部题目	8
E6 实现逻辑错误	A02、C02、D01、D02	4
E7 测试过拟合或偶然正确	B01、D01、D02	3
E8 幻觉、自相矛盾或证据不足	A01、B01、B02、D01	4

MVP 每题至少 4 条轨迹，共至少 32 条。四象限各题尽量齐全：结果对/过程对、结果对/过程错、结果错/过程前段合理、结果错/过程错。正式版目标为每题 6 条，共约 72 条。

10 标注与数据制作规则

每条轨迹必须先由人确定 gold 标签，再运行评估器。评估器预测不能回填为 gold。

最低字段如下：

```
trace_id: A01-T03
problem_id: A01-pack-cost
source: manual_injection
final_correct: true
process_correct: false
first_error_step: 3
error_types: [E3]
evidence: "步骤 3 声称最低单位价格必然产生最低总价；需求量和包装离散性构成反例。"
annotator: guo_haoyang
review_status: reviewed
```

单错误注入优先于多错误注入。需要多错误时，记录每个修改位置，但 gold 的 first_error_step 仍只有一个。所有“结果对/过程错”样本和所有错误样本都应人工复核。

11 每题目录与文件要求

```
benchmarks/problems/<internal-id>/
├── metadata.yaml
├── statement_or_spec.md
├── reference_solution.cpp
├── generator.py
├── checker.py
├── rubric.yaml
├── README.md
├── tests/
│   ├── manifest.yaml
│   ├── sample_like/
│   ├── boundary/
│   ├── adversarial/
│   └── random/
```

metadata.yaml 记录外部题号、官方链接、访问日期、内部层级、知识点、约束摘要、版权处理方式和文件哈希。生成器必须使用固定种子。测试清单记录构造目的，而不是只保存输入文件名。

12 阶段一验收标准

阶段一在满足以下条件后关闭：

- 候选矩阵不少于 16 题，本文件列出 20 题。
- 8 题 MVP 与 12 题正式版均已冻结，并说明每次扩题的增量价值。
- 8 题覆盖模拟、贪心、排序、二分、DP、图论、并查集和线段树。
- 每题给出来源链接、内部层级、参考算法、复杂度、主要错误和测试重点。
- 已确定引用与版权边界，不依赖洛谷私有测试或第三方题解。
- 已建立 E1-E8 覆盖表和至少 32 条 MVP 轨迹的制作目标。
- 仓库中准备保存 stage1_problem_selection.md、problem_catalog.yaml 和 annotation_guideline.md。

建议上传后的检查命令：

```
test -f docs/planning/stage1_problem_selection.md
test -f benchmarks/problem_catalog.yaml
test -f annotations/annotation_guideline.md
python - <<'PY'
from pathlib import Path
import yaml

data = yaml.safe_load(Path('benchmarks/problem_catalog.yaml').read_text(encoding='utf-8'))
assert len(data['candidates']) == 20
assert len([x for x in data['candidates'] if x['selection'] == 'mvp']) == 8
print('stage1 catalog ok')
PY
```

13 进入阶段二前的工作清单

- 5. 把本阶段三个仓库文件上传到指定路径，并补传阶段 0 DOCX。
- 6. 在 PROJECT_PLAN.md 中把阶段一状态更新为完成，附本文件链接。
- 7. 建立 Python 包、JSON Schema、.env.example 和无密钥 mock 流程。
- 8. 只实现 A01 的完整纵向切片：规格、参考解、生成器、检查器、一份正确轨迹、一份错误轨迹、聚合报告。
- 9. A01 通过自动测试后，再复制目录模板到其余七题。

14 风险与应对

风险	影响	应对
题面或测试版权不清	无法公开完整复现	使用链接和自写摘要；采用自编等价规格与独立测试
8 题同时开发	纵向链路迟迟不能运行	先完成 A01，再逐题扩展
高难题参考解本身有错	gold 和测试失真	交叉验证、随机对拍、小规模暴力解
仅靠代码是否通过判断过程	无法识别答案对但过程错	保留公开结构化步骤，人工制作反例和 gold
单人标注偏差	定位指标可信度有限	全量复核错误样本；争取教练或另一名选手抽检并报告一致率
沙盒隔离不足	运行陌生代码有安全风险	首版只运行仓库内已审代码；阶段三再加入受限执行器

15 当前状态

阶段一选题设计已完成，尚未声称以下事项已经完成：8 题代码与测试、Hy3 真实调用、32 条 gold 轨迹、定位准确率、误报率、人工双人复核或 demo。这些结果必须在后续阶段通过真实运行产生。